

AprovaEdu Analytics - Relatório Final

Análise dos dados de uma rede de cursinhos pré-vestibular (2021–2025) para apoiar a coordenação pedagógica em três frentes: desempenho dos alunos, efetividade dos cursos e fatores associados à aprovação no vestibular.

1. Sumário executivo

- **A taxa de aprovação é estável em torno de 33%** (entre 30,0% e 36,2% ao longo dos cinco anos), sem tendência clara de melhora ou piora. O volume absoluto de matrículas e de aprovações cresce, mas a *proporção* de aprovados se mantém.
 - **Não há evidência de que presença nas aulas esteja associada à aprovação.** Aprovados e não aprovados têm a mesma presença média (84,0%), e dois testes estatísticos formais não apontam associação. A presença é muito concentrada (quase todos entre 81% e 87%), o que limita seu poder de diferenciar os grupos.
 - **As matérias têm desempenho parecido entre si**, as diferenças no índice composto são modestas. História aparece à frente; Sociologia, Matemática e Biologia atrás. Redação é analisada à parte por estar numa escala e num tipo de prova diferentes.
 - **O maior achado de negócio pode ser a qualidade do dado na origem.** O volume de retrabalho de limpeza que esta base exigiu (matéria escrita de 5 formas diferentes em 5 tabelas, escala de nota inconsistente, duplicidade de cadastro em aprovações) é, em si, um problema de processo que antecede qualquer análise.
 - **O canal de captação mostra diferença relevante:** alunos vindos de *Indicação* aprovam mais (43,4%) do que os de *WhatsApp* (31,1%).
-

2. Contexto e objetivo

A rede acumulou, ao longo de cinco anos, dados de alunos, professores, matérias, cursos, simulados, presença e aprovações, vindos de fontes internas diferentes, daí a heterogeneidade de formato e qualidade. A coordenação quer entender melhor o desempenho, a efetividade dos cursos e os fatores de aprovação. Este relatório responde às quatro perguntas obrigatórias:

1. Evolução da taxa de aprovação ao longo dos anos.
 2. Relação entre presença nas aulas e aprovação.
 3. Cursos/matérias com melhor desempenho.
 4. Recomendações práticas para a coordenação.
-

3. Dados e metodologia

Fonte. Nove tabelas relacionais: quatro dimensões (estudantes, professores, ofertas_curso, simulados) e cinco fatos (matriculas, aulas, presencas_aulas, resultados_simulados, aprovacoes_vestibular), totalizando ~110 mil linhas. A integridade referencial da base bruta é intacta (chaves primárias únicas, sem chaves estrangeiras sozinhas); o trabalho de tratamento incidiu sobre **valor e escala**, não sobre chaves.

Modelo. Os dados tratados são carregados num banco relacional SQLite com chaves primárias e estrangeiras declaradas. Sobre ele são construídas duas bases analíticas: `base_analitica_aluno` (uma linha por aluno) e `base_analitica_materia` (uma linha por matéria). O detalhe de cada decisão de tratamento está em [DECISOES.md](#); o dicionário completo em [docs/data_dictionary.md](#).

Decisões que mudam o resultado (resumo — detalhe em `DECISOES.md`):

- **Escala de nota por matéria.** Redação usa a escala ENEM (0–1000); as demais matérias, 0–100. Notas fora da faixa da própria matéria viram ausentes, nunca truncadas. Aplicar uma faixa 0–100 global descartaria toda a Redação, erro que mudaria a resposta da Q3.
 - **Canonicalização com falha alta.** Toda categórica passa por um mapa canônico explícito; um valor desconhecido interrompe o pipeline em vez de criar uma categoria fantasma.
 - **Presença efetiva** = Presente ou Atrasado.
 - **Taxa de aprovação** = alunos distintos aprovados ÷ matriculados distintos (status ativo, concluída ou truncada).
 - **Deduplicação** de negócio nas tabelas de fato e remoção de 15 duplicidades de cadastro em aprovações (identificadas pelo campo chamada com par idêntico confirmado).
-

4. Respostas às perguntas obrigatórias


Q1 — Evolução da taxa de aprovação por ano

A base não traz a taxa pronta, e há três contagens facilmente confundíveis. Apresentá-las lado a lado deixa o denominador auditável:

Ano	(a) Matriculados distintos	(b) Aprovações brutas	Aprovações após dedup	(c) Aprovados distintos	Taxa = c/a
2021	138	50	50	50	36,2%
2022	170	53	53	53	31,2%
2023	218	78	77	77	35,3%
2024	263	87	79	79	30,0%
2025	233	86	80	80	34,3%

A **taxa correta é (c) ÷ (a)** — pessoas no numerador e no denominador. Dividir o volume de eventos (b) por matriculados misturaria contagem de eventos com contagem de pessoas e poderia gerar valores acima de 100%. Note que a coluna (b) bruta (354 no total) cai para 339 após remover as 15 duplicidades de cadastro; depois disso, por ano, o volume de aprovações coincide com aprovados distintos (nenhum aluno tem duas aprovações no mesmo ano).

Leitura. A taxa é **estável, na casa de 30–36%** (média 33,4%), sem tendência forte. O que muda é a *esca/a*: matrículas quase dobram (138 → 263 no pico) e as aprovações acompanham, mantendo a proporção. Ou seja, a rede cresceu sem perder nem ganhar eficiência de aprovação.



Q2 — Presença nas aulas × aprovação

Método. Presença efetiva = Presente + Atrasado, por aluno, sobre todas as suas presenças. Comparei a distribuição entre aprovados (n=306) e não aprovados (n=494) e apliquei dois testes formais: Mann-Whitney (diferença de distribuição) e correlação point-biserial (força da associação).



Resultado — não há evidência de associação:

Métrica	Valor
Presença média — aprovados	84,0%
Presença média — não aprovados	84,0%
Mann-Whitney U (p-valor)	73727 (p = 0,559)
Correlação point-biserial r (p-valor)	-0,007 (p = 0,844)

O p-valor de 0,56 no Mann-Whitney não permite rejeitar a hipótese de distribuições iguais, e a correlação point-biserial é praticamente zero. A visão por faixa de presença confirma: não há tendência monotônica (a faixa 75–85% até tem a maior taxa, 41%, mas com o maior n; a faixa <75% tem só 15 alunos).

Faixa de presença	n	Aprovados	Taxa de aprovação
< 75%	15	4	26,7%

75–85%	458	188	41,0%
85–90%	269	94	34,9%
> 90%	58	20	34,5%



Leitura honesta. A resposta da Q2 é um **resultado nulo**, e isso é uma resposta válida — não uma falha da análise. A presença é uma variável muito comprimida (mediana ~84%, quase todos entre 81% e 87%), então tem pouco poder de separar os grupos. Afirar "presença leva à aprovação" com base numa diferença de frações de ponto percentual, sem teste, seria enganoso. **Associação não é causalidade**, e aqui não há sequer associação mensurável.


Q3 — Matérias com melhor desempenho

Método. Para cada matéria, quatro indicadores: nota média normalizada (*nota_pct*), presença média dos alunos da matéria, taxa de conclusão de matrícula e taxa de aprovação dos alunos associados. Cada indicador é padronizado em z-score e o **índice composto é a média simples dos quatro** (sem pesos arbitrários — mais transparente e defensável).

Redação fica fora do ranking por z-score. É prova dissertativa (escala 0–1000); seu *nota_pct* médio (~72%) está uma ordem de grandeza fora das objetivas (~61%). Incluí-la distorceria a padronização das demais. Ela é reportada à parte, com ressalva: uma redação avaliada em banca não é estritamente comparável a uma prova objetiva, mesmo após normalização.


#	Matéria	Índice composto	Nota (%)	Presença	Conclusão	Aprovação	n (resultados)
1	História	+1,12	61,5	84,2	74,6	40,0	1.768
2	Filosofia	+0,35	61,6	84,1	70,6	39,3	1.687
3	Português	+0,34	62,0	84,7	69,0	38,3	1.760
4	Física	+0,28	61,0	84,5	67,7	41,0	1.928
5	Química	+0,15	61,4	84,1	70,0	39,2	1.786
6	Inglês	–0,20	61,3	83,6	68,5	39,7	1.617
7	Geografia	–0,21	60,7	84,7	70,0	38,7	1.727
8	Matemática	–0,48	60,9	83,8	71,4	38,3	1.840
9	Biologia	–0,50	61,1	83,0	71,0	39,0	1.807
10	Sociologia	–0,83	60,9	83,3	69,0	38,9	1.739

—	Redação (à parte)	—	71,9	83,6	69,0	38,3	1.727
---	-------------------	---	------	------	------	------	-------



Leitura com cautela sobre a magnitude. O z-score amplifica diferenças pequenas: em valor absoluto, as matérias objetivas são muito parecidas (nota média entre 60,7% e 62,0%, presença entre 83% e 85%). História lidera puxada pela **maior taxa de conclusão** (74,6%), não por nota. O heatmap por eixo é mais acionável que o ranking geral, porque mostra *onde* cada matéria se destaca ou falha:

Q3 — Heatmap matéria × indicador (z-score, matérias objetivas)



Exemplos que o heatmap revela: **Física** tem a maior taxa de aprovação (+2,3 z) mas a menor conclusão (-1,4 z) — sinal de evasão nas ofertas de Física, apesar do bom resultado de quem fica. **Português** tem a melhor nota (+2,0 z) mas aprovação abaixo da média. Esses contrastes por eixo são mais úteis para a coordenação do que a posição no ranking.

Q4 — Recomendações para a coordenação

Cinco recomendações no formato **achado** → **evidência** → **ação** → **impacto esperado** → **como medir**, priorizadas por impacto × esforço.

R1. Padronizar a captura de dado na origem (maior impacto, esforço médio). - *Achado*: a informação de matéria aparece em 5 tabelas escrita de até 28 formas diferentes; a nota de simulado mistura duas escalas; 15 aprovações eram cadastro duplicado. - *Evidência*: medido no tratamento — a canonicalização precisou de mapa explícito, e a duplicidade só foi resolvida por um campo de auditoria da própria base. - *Ação*: padronizar a entrada (listas fechadas/dropdowns para matéria, universidade, status; validação de faixa de nota por tipo de prova; verificação de duplicidade no cadastro de aprovação). - *Impacto*: menos retrabalho de análise e indicadores mais confiáveis, mais cedo. - *Como medir*: nº de grafias distintas por campo e nº de duplicidades de cadastro por safra, ao longo do tempo (meta: cair a cada semestre).

R2. Não tratar frequência como alavanca de aprovação sem nova evidência (alto impacto, baixo esforço). - *Achado*: não há associação mensurável entre presença e aprovação nesta base. - *Evidência*: presença média idêntica (84,0%) entre aprovados e não; Mann-Whitney $p=0,56$; point-biserial $r=-0,007$. - *Ação*: evitar investir em políticas de frequência esperando ganho de aprovação; investigar outras alavancas (nota diagnóstica, desempenho em simulado). Reavaliar se a política de presença mudar a distribuição (hoje comprimida demais para discriminar). - *Impacto*: evita gastar esforço numa alavanca que os dados não sustentam. - *Como medir*: refazer o teste a cada safra; só considerar a presença uma alavanca se a associação aparecer com significância.

R3. Investigar a evasão nas ofertas de Física (impacto médio, esforço baixo). - *Achado*: Física tem a maior taxa de aprovação dos alunos, mas a menor taxa de conclusão de matrícula. - *Evidência*: heatmap Q3 — Física em +2,3 z de aprovação e -1,4 z de conclusão. - *Ação*: levantar por que alunos abandonam as ofertas de Física (carga, horário, didática) mesmo com bom resultado final. - *Impacto*: reter alunos numa matéria que, para quem conclui, entrega bom resultado. - *Como medir*: taxa de conclusão das ofertas de Física por


safra.

R4. Fortalecer o canal de Indicação (impacto médio, esforço médio). - *Achado:* alunos captados por Indicação aprovam mais (43,4%) que os de WhatsApp (31,1%). - *Evidência:* aprovação por canal em `base_analitica_aluno`. - *Ação:* programa estruturado de indicação (incentivo a alunos/famílias que indicam). - *Impacto:* aumentar a fatia de um canal que converte melhor em aprovação. - *Como medir:* taxa de aprovação por canal, por safra, e participação de cada canal na captação.

R5. Registrar explicitamente o desfecho de todos os alunos (impacto alto, esforço médio). - *Achado:* não existe tabela de "reprovados"; o não-aprovado é inferido por ausência em aprovações. - *Evidência:* a única fonte de desfecho é `aprovaes_vestibular`; quem não aparece é assumido como não aprovado. - *Ação:* passar a registrar o desfecho de vestibular de cada aluno (aprovado/não/não prestou). - *Impacto:* habilita análise causal e modelo preditivo confiável, hoje limitados pela inferência por ausência. - *Como medir:* % de alunos com desfecho de vestibular registrado explicitamente (meta: 100%).

5. Análises complementares

Aprovações por universidade. UECE (60) e UFC (51) concentram quase um terço das 339 aprovações, seguidas de UNILAB (35) e das demais estaduais/federais da região.



Aprovação por canal de captação.

Canal	n	Taxa de aprovação
Indicação	106	43,4%
Google	126	40,5%
Feira escolar	105	39,0%
Instagram	238	34,5%
WhatsApp	106	31,1%

Aprovação por escola de origem. Diferenças modestas: Privada 39,9%, Pública 36,6%, Federal 35,7% — sem um gap dramático entre origens.

6. Interpretação e discussão

Os resultados apontam para uma rede **estável e homogênea**: a taxa de aprovação não se move muito no tempo (Q1), as matérias entregam desempenho parecido (Q3) e a presença — que intuitivamente pareceria um forte preditor — não discrimina aprovados de não aprovados (Q2). Essa homogeneidade tem uma consequência prática: **os ganhos provavelmente virão de alavancas específicas e mensuráveis** (o canal de Indicação, a evasão em Física, a qualidade do cadastro), não de uma intervenção geral do tipo "aumentar a presença de todo mundo".

O ponto de conexão entre as perguntas é a **qualidade do dado**: a mesma fragilidade de cadastro que gerou 15 aprovações duplicadas e 28 grafias de matéria é o que hoje limita uma análise causal (não há desfecho explícito). Investir no processo de captura (R1, R5) destrava as demais análises.

7. Decisões de desenvolvimento

As decisões técnicas e analíticas mais relevantes, com o critério por trás de cada uma, estão em [DECISOES.md](#). As de maior efeito no resultado:

- **Escala de nota por matéria** (e não global): muda a resposta da Q3 — sem ela, a Redação seria descartada como "fora de escala".
 - **Falhar alto na canonicalização**: uma grafia nova interrompe o pipeline em vez de virar categoria fantasma silenciosa.
 - **Ausente, não truncado**: outliers de nota viram ausentes; truncar inflaria a média.
 - **Taxa por pessoas** (não por eventos): evita o risco de taxa acima de 100%.
 - **Reprodutibilidade por `metrics.json`**: todo número do relatório sai do código.
-

8. Limitações

- **O alvo é inferido por ausência**. Não há tabela de reprovados; "não aprovado" = não aparece em aprovações. Isso é uma premissa, não um dado observado (ver R5).
 - **A presença é comprimida**. O intervalo estreito (70%–97%, quase todos entre 81% e 87%) reduz o poder de qualquer teste sobre ela — o resultado nulo da Q2 deve ser lido com essa ressalva.
 - **Redação não é estritamente comparável** às objetivas, mesmo normalizada (prova dissertativa, avaliada em banca, distribuição diferente).
 - **Amostras ficam pequenas em cortes finos** (339 aprovações no total; faixas de presença com $n=15$). Diferenças pequenas entre subgrupos podem não ser estáveis.
-

9. Conclusões

A rede é estável e homogênea: taxa de aprovação ~33%, matérias parecidas entre si, e presença sem poder preditivo de aprovação. A recomendação central é **priorizar alavancas específicas e mensuráveis** — qualidade do cadastro na origem, retenção em Física, e o canal de Indicação — em vez de intervenções gerais que os dados não sustentam. E, transversalmente, **melhorar o processo de captura de dado**, que hoje é o principal fator limitante tanto da operação quanto de análises futuras mais ambiciosas (causalidade, score preditivo).

10. Reprodutibilidade e anexos

- **Rodar tudo**: `python run_pipeline.py` recria o banco, os dados tratados, as bases analíticas, as figuras e o `metrics.json`, de forma idempotente.
- **Testes**: `pytest` (11 testes de qualidade travando as decisões críticas).
- **Dados tratados**: `data/processed/*.csv`. **Banco**: recriado em `db/aprovaedu.db`.
- **Números**: `reports/metrics.json`. **Figuras**: `reports/figures/`.
- **Decisões**: `reports/DECISOES.md`. **Dicionário**: `docs/data_dictionary.md`. **Uso de IA**: `docs/USO_DE_IA.md`.